

QUATRO NORTE CONSULTING · GRUPO 01

Custo anual de manutenção por carreta

Modelo Preditivo

Fatores determinantes e modelagem do custo anual (CAD \$/ano, real) da frota própria de leasing/rental no Canadá — janela 2020–2025

Marlon Wenzel · Jeison Lima · Rodrigo Queiroz · Giovani Cani

A empresa e a operação

- Empresa de leasing/rental de carretas no Canada (secas e refrigeradas, até 53 pés).
- Manutenção própria: oficinas registram ordens de serviço com mão de obra e peças.
- Todos os custos em dólares canadenses (CAD); operação integralmente no Canadá.
- Objetivo de negócio: apoiar orçamento anual e priorização de manutenção da frota.
- Fonte inicial do estudo: base consolidada de Ordens de Serviço (2020–2025).

9.859

Carretas únicas

223.590

Ordens de serviço acumuladas no período

CAD \$ 82.428 M

Custo interno (real) acumulado no período

2020–2025

Período

A pergunta de pesquisa

Quais fatores mais influenciam o CUSTO ANUAL INTERNO de manutenção por carreta e como estimá-lo a partir das características operacionais, históricas e estruturais da frota?

- **Variável de interesse:** custo anual de manutenção por carreta (CAD \$/ano), em valores reais.
- Grão de análise: carreta × ano.
- Escopo: todo o custo interno absorvido pela empresa (preventiva + corretiva).
- Correção monetária obrigatória pela inflação canadense (CPI) para comparar anos em termos reais.

Objetivos gerais e específicos

Analisar os fatores que influenciam o custo anual de manutenção por carreta (CAD, corrigido pela inflação), identificando as variáveis de maior capacidade explicativa e desenvolvendo modelos estatísticos e de ML para estimá-lo.

- Consolidar a análise a partir da base única de OS.
- Definir a variável resposta anual e corrigi-la pelo CPI (Canadian Price Index) do Canadá.
- Realizar EDA rigorosa (univariada, relação com Y, ranking) das variáveis candidatas.
- Selecionar variáveis de forma fundamentada (associação, multicolinearidade, domínio).
- Desenvolver e avaliar modelos estatísticos e de Machine Learning (split temporal).

Hipóteses de trabalho

Hipótese	Descrição
H1	Idade da carreta eleva o custo anual
H2	Maior uso/quilometragem eleva o custo anual
H3	Histórico de manutenção prevê o custo futuro
H4	Características do ativo influenciam o custo
H5	Região/operação influencia o custo
H6	Contrato (duração/tipo) influencia o custo

Base consolidada inicial

- Fonte única: fato_wo_ml_2020-01-01_to_2025-12-31.csv (1 linha = 1 OS).
- Extração SQL, modelo estrela, joins e feature engineering.
- 223.590 OS · 9.859 carretas únicas · 2020–2025.
- VMRS: código padronizado do sistema reparado (PM, freios, pneus, reefer...).

Arquitetura metodológica

Base consolidada (CSV)

↓ Validação de qualidade

↓ Variável resposta anual

↓ Correção CPI Canadá

↓ EDA (uni/bivariada)

↓ Correlação e testes

↓ Multicolinearidade/VIF

↓ Ranking

↓ Seleção de variáveis

↓ Modelagem (estat.+ML)*

↓ Avaliação / discussão*

**Fase 2*


Y = custo anual de manutenção por carreta

Y = soma do custo interno da carreta no ano (CAD), deflacionado pelo CPI Canada (dez/2025)
Grão: carreta × ano

- Média CAD \$ 1673.72/ano · mediana CAD \$ 812.55/ano · p90 CAD \$ 4221.76.
- Assimetria 3.79 (cauda longa), tratada por log1p e modelos robustos.
- Apenas 3.23% de carreta-anos com custo zero: o grão anual praticamente elimina a zero-inflação.
- Custo interno total: CAD \$ 77.18 mi nominal / CAD \$ 82.428 mi real (dez/2025).

Custos reais pelo CPI do Canadá

- Todos os custos em CAD, corrigidos pelo CPI all-items do Canada (StatCan, vetor v41690973).
- Base de comparação: dezembro de 2025.
- Inflação acumulada no período: ~20% (2020→2025).
- A correção isola mudanças REAIS de custo da mera perda do poder de compra.



Dicionário das variáveis candidatas

São 25 variáveis explicativas candidatas da fonte inicial. A tabela lista ainda id, ano, o alvo Y e os 2 componentes de Y (n_os_ano, custo_medio_por_os_ano).

variável	tipo / papel
id_carreta	id
ano	temporal
custo_ano_real	Y (resposta, CAD real)
n_os_ano	componente de Y
custo_medio_por_os_ano	componente de Y
n_sistemas_vmrs_distintos_ano	operacional
share_pm_ano	operacional
vmrs_predominante_ano	operacional (cat.)
km_acumulado_fim_ano	exposição
km_rodado_ano	exposição
regiao_operacao	geográfica (cat.)
provincia_estado	geográfica (cat.)
cod_montadora	ativo (cat.)
descricao_carreta	ativo (cat.)
ano_modelo	ativo (quant.)

variável	tipo / papel
eixos	ativo (quant.)
comprimento	ativo (quant.)
flag_refrigerado	ativo (cat.)
unit_subtype	ativo (cat.)
tire_size	ativo (cat.)
suspension_type	ativo (cat.)
new_used_indicator	ativo (cat.)
tailgate_flag	ativo (cat.)
idade_carreta	ativo derivada (quant.)
custo_ano_anterior	histórico defasado
n_os_ano_anterior	histórico defasado
custo_acum_ate_ano_anterior	histórico defasado
n_os_acum_ate_ano_anterior	histórico defasado
anos_ativo_ate_ano_anterior	histórico defasado
km_acumulado_inicio_ano	hist. defasado (preditivo)

Descrição das variáveis candidatas

Atributos do ativo

cod_montadora — fabricante da carreta
ano_modelo — geração tecnológica do ativo
eixos — configuração estrutural (nº de eixos)
comprimento — porte físico (pés)
flag_refrigerado — refrigerada (reefer) × seca
unit_subtype — subtipo operacional da unidade
tire_size — dimensão dos pneus
suspension_type — tipo de suspensão
new_used_indicator — nova ou usada na aquisição
descricao_carreta — tipo/classe da unidade (proxy de modelo)

Geografia e idade

idade_carreta — anos desde a entrada em serviço
regiao_operacao — região predominante de operação
provincia_estado — província predominante (cobertura ~54%)

Uso e operação do ano

km_rodado_ano — km percorridos no ano
km_acumulado_fim_ano — odômetro no fim do ano
n_sistemas_vmrs_distintos_ano — variedade de sistemas reparados
share_pm_ano — fração de OS preventivas (PM)
vmrs_predominante_ano — sistema VMRS mais reparado no ano


Histórico defasado (cenário preditivo)

custo_ano_anterior — custo real do ano t-1
n_os_ano_anterior — nº de OS em t-1
custo_acum_ate_ano_anterior — custo real acumulado até t-1
n_os_acum_ate_ano_anterior — OS acumuladas até t-1
anos_ativo_ate_ano_anterior — anos de histórico disponível
km_acumulado_inicio_ano — odômetro no início do ano

Estatísticas descritivas


variável	N	media	mediana	desvio padrão	min	max	assimetria
custo_ano_real	49248	1673.724	812.55	2400.748	0.0	62230.924	3.786
ano_modelo	49242	2014.545	2015.0	5.887	1982.0	2026.0	-0.434
eixos	49157	2.078	2.0	0.276	1.0	4.0	3.226
comprimento	48588	52.256	53.0	3.686	28.0	60.0	-5.024
idade_carreta	49242	8.384	7.0	5.791	0.0	39.0	0.507
km_acumulado_fim_ano	48976	178122.519	111110.5	199147.442	0.0	3479389.0	2.165
km_rodado_ano	39076	23689.68	12698.5	29090.836	0.0	249676.0	2.358
n_sistemas_vmrs_distintos_ano	49248	2.5	2.0	1.549	0.0	12.0	1.086
share_pm_ano	49248	0.325	0.25	0.333	0.0	1.0	0.93
n_os_ano	49248	4.536	3.0	4.275	0.0	59.0	2.411
custo_medio_por_os_ano	49248	339.18	244.318	354.068	0.0	19177.732	7.321
n_os_ano_anterior	39389	4.476	3.0	4.267	0.0	59.0	2.425
n_os_acum_ate_ano_anterior	49248	9.684	6.0	12.955	0.0	131.0	2.89
anos_ativo_ate_ano_anterior	49248	2.258	2.0	1.68	0.0	5.0	0.17
custo_ano_anterior	39389	1610.857	765.398	2334.785	0.0	62230.924	3.878
custo_acum_ate_ano_anterior	49248	3402.821	1343.059	5992.338	0.0	123769.413	4.264

Evolução do custo anual real (2020–2025)




Crescimento consistente do custo anual real de manutenção ao longo do período analisado, mesmo após a correção pela inflação. Média e mediana apresentam tendência de alta, indicando que o aumento dos custos ocorre de forma disseminada na frota. A diferença entre média e mediana evidencia a presença de ativos com custos excepcionalmente elevados, característicos de uma distribuição assimétrica.


Histogramas e distribuições




Distribuição fortemente assimétrica à direita — a maioria dos veículos custa pouco (mediana ~R\$ 1.000) e uma cauda longa de outliers chega a R\$ 12.000.



Mesmo padrão assimétrico — a maior parte da frota roda menos de 20.000 km/ano, com outliers acima de 75.000 km.




Distribuição quase idêntica à do custo atual, o que indica forte potencial preditivo — custo passado tende a ser o melhor previsor do custo futuro.




Variável de contagem com moda em 1–2 ordens de serviço e cauda até ~20, padrão típico Poisson. Os outliers acima de 12 OS indicam veículos com manutenção recorrente, que merecem atenção especial.


Histogramas — atributos do ativo




Frota concentrada entre 2005 e 2024, com mediana em torno de 2015 e um pico expressivo em ~2020. Os outliers abaixo de 1999 são poucos veículos muito antigos, que merecem verificação se ainda estão ativos.



Variável quase constante — a esmagadora maioria das carretas tem 2 eixos, com uma pequena fração de 3 e casos raros de 1 e 4. Com tão pouca variabilidade, tende a ter baixo poder preditivo no modelo.




Fortemente concentrado num único valor (~53 pés, o padrão do mercado), com os demais comprimentos aparecendo como outliers no boxplot. Assim como eixos, é uma variável de baixa variância — os poucos comprimentos atípicos podem, porém, sinalizar equipamentos especiais com perfil de custo diferente.




Distribuição bem mais equilibrada, com platô entre 0 e 8 anos e decaimento gradual até ~23 anos; mediana de ~7 anos. É a versão mais "utilizável" de ano_modelo para o modelo, com boa dispersão e leitura direta


Histogramas — uso e operação no ano




Assimetria à direita típica de quilometragem acumulada — a maioria dos veículos tem menos de 200.000 km, com cauda longa até ~850.000 km e muitos outliers acima de ~530.000 km. A mediana em torno de 120.000 km reflete uma frota relativamente jovem, coerente com a idade mediana de ~7 anos vista antes.



Distribuição de contagem com moda em 2 sistemas distintos afetados por ano e decaimento rápido, com outliers acima de 6. Veículos que acionam muitos sistemas diferentes no mesmo ano são candidatos a problema crônico — e essa variável apareceu como uma das explicativas mais fortes (Spearman 0.70), o que faz sentido: mais sistemas afetados, mais custo.




Distribuição peculiar, com três picos claros: 0 (nenhuma manutenção preventiva), ~0.5 e 1.0 (só preventiva) — comportamento típico de proporção com poucos eventos no denominador (com 2 OS, o share só pode ser 0, 0.5 ou 1). A correlação negativa com custo vista antes sugere que veículos com mais preventiva custam menos.




Contagem com moda em 2 OS/ano, mediana de ~3 e cauda até 20+, com outliers acima de 12. Como é componente direto do Y (custo = n° OS $\times$ custo médio), serve para entender o comportamento da frota, mas não pode entrar como preditora no modelo.


Histogramas — histórico defasado e custo por OS




Forte assimetria à direita, com concentração de carretas em baixos custos acumulados e poucos ativos concentrando gastos muito elevados. A grande quantidade de outliers evidencia uma parcela reduzida da frota com histórico de manutenção significativamente superior ao restante.



A maioria das carretas acumula poucas ordens de serviço ao longo do histórico, enquanto uma pequena parcela apresenta recorrência elevada de intervenções. O comportamento reforça que existem ativos com maior intensidade de manutenção, refletindo diferentes perfis de utilização e desgaste.




A distribuição é relativamente equilibrada entre os anos disponíveis de histórico, sem concentração relevante de outliers. O histórico contempla ativos em diferentes estágios de acompanhamento, permitindo avaliar a influência da experiência operacional ao longo do tempo.




Distribuição assimétrica, concentrando ordens de serviço de menor custo e poucos reparos com valores significativamente mais elevados. A presença de diversos outliers indica eventos de manutenção de alto impacto financeiro, característicos de operações de manutenção pesada.


Boxplots do custo anual por categoria




As carretas refrigeradas apresentam mediana de custo mais alta e dispersão muito maior do que as não refrigeradas.



RC2, RHM2 e HC3 concentram os maiores custos medianos e a maior variabilidade; os demais subtipos ficam em níveis inferiores.




As medianas são relativamente próximas, mas Utility apresenta a maior dispersão; Mond concentra os menores custos.




A categoria 10 possui a maior mediana e a maior amplitude de custos; a categoria SEM_OS permanece próxima de zero.


Boxplots por categoria — configuração e tipo do ativo




As configurações 53' T/A Reefer e 53' Tridem HEA apresentam os maiores custos medianos e a maior variabilidade.



A medida 275/80R22.5 se destaca pela maior mediana e dispersão; as demais medidas apresentam distribuições mais próximas.




Hendrickson apresenta a maior mediana e ampla dispersão, enquanto Chalmers concentra os menores custos.




As unidades novas têm mediana ligeiramente superior e maior dispersão, embora exista forte sobreposição com as usadas.

Boxplots por categoria — geografia



Balzac e Langley apresentam os maiores custos medianos e maior dispersão; Winnipeg01 permanece concentrada próxima de zero.




New Brunswick, Manitoba e Saskatchewan apresentam medianas mais elevadas; New Brunswick e Manitoba também exibem maior variabilidade.

Relação individual de cada variável com Y

variável	spearman	papel
custo_medio_por_os_ano	0.786	componente de Y
n_os_ano	0.769	componente de Y
n_sistemas_vmrs_distintos_ano	0.704	explicativa
n_os_ano_anterior	0.54	explicativa
custo_ano_anterior	0.536	explicativa
km_rodado_ano	0.53	explicativa
n_os_acum_ate_ano_anterior	0.461	explicativa
custo_acum_ate_ano_anterior	0.452	explicativa
km_acumulado_fim_ano	0.428	explicativa
anos_ativo_ate_ano_anterior	0.254	explicativa
share_pm_ano	-0.172	explicativa
comprimento	-0.097	explicativa
ano_modelo	0.053	explicativa


variável	eta	n_categorias
descricao_carreta	0.5947	253
unit_subtype	0.5505	26
flag_refrigerado	0.4321	2
vmrs_predominante_ano	0.3423	23
cod_montadora	0.2383	26
tire_size	0.1546	24
suspension_type	0.1473	9
provincia_estado	0.1424	24
new_used_indicator	0.1199	2
regiao_operacao	0.0775	10

Ranking de associação com o custo anual



- Uso (km) e histórico defasado lideram entre as quantitativas.
- Refrigerado e subtipo lideram entre as categóricas.
- Idade tem efeito direto fraco.
- Componentes aritméticos de Y são excluídos do ranking de explicadores.

Multicolinearidade — matriz e VIF



variável	vif
idade_carreta	13.51
n_os_acum_ate_ano_anterior	12.87
ano_modelo	12.21
custo_acum_ate_ano_anterior	9.36
n_os_ano_anterior	5.99
custo_ano_anterior	4.84
n_os_ano	3.95
anos_ativo_ate_ano_anterior	3.05
n_sistemas_vmrs_distintos_ano	2.75
km_rodado_ano	1.57
km_acumulado_fim_ano	1.49
share_pm_ano	1.22

Seleção inicial das variáveis do modelo

variável	sugestão inicial
tailgate_flag	remover
n_os_ano	remover
custo_medio_por_os_ano	remover
descricao_carreta	remover
ano_modelo	remover
idade_carreta	manter
eixos	manter
comprimento	manter
flag_refrigerado	manter
unit_subtype	manter
tire_size	manter
suspension_type	manter
new_used_indicator	manter
cod_montadora	manter

variável	sugestão inicial
regiao_operacao	manter
provincia_estado	manter
vmrs_predominante_ano	manter (só explicativo)
km_rodado_ano	manter (só explicativo)
n_sistemas_vmrs_distintos_ano	manter (só explicativo)
share_pm_ano	manter (só explicativo)
km_acumulado_fim_ano	explicativo / inicio_ano no preditivo
n_os_ano_anterior	manter
custo_ano_anterior	manter
n_os_acum_ate_ano_anterior	manter
custo_acum_ate_ano_anterior	manter
anos_ativo_ate_ano_anterior	manter

Critérios: ranking, VIF, redundância, vazamento temporal e coerência de domínio.

Estudos selecionados e trabalhos-base

Autor (ano)	Tema do estudo	Método / achado principal	Contribuição para o projeto
Katreddi, Thiruvengadam, Thompson, Schmid e Padmanaban (2023)	Custo de manutenção de caminhões de entrega (diesel/GNV)	RF, XGBoost, ANN e Super Learner; Super Learner o melhor ($R^2=97,28\%$)	Fundamenta o uso de árvores e ensembles para capturar a relação não linear entre operação e custo.
Katreddi, Thiruvengadam, Thompson e Schmid (2023)	Custo em veículos pesados; frotas heterogêneas	Mixed-Effects Random Forest (MERF)	Apoia o uso de variáveis categóricas de agrupamento (montadora, subtipo, refrigeração) como preditoras.
Sun, Guo, Sun, Yang e Hao (2024)	Previsão de custo a partir de dados de manutenção	Mixed Weibull + estimativa iterativa sobre o histórico	Mostra que o próprio histórico de manutenção já prevê o custo futuro — base para as variáveis históricas defasadas.
Adekitan, Adetokun e Okokpujie (2018)	Componentes de custo de manutenção veicular	Rede neural artificial (ANN); $R=0,766$	Confirma sinal preditivo em uso e histórico, mas indica que redes neurais não superam os métodos de árvore.

As referências favorecem modelos de árvore/ensemble, coerente com os resultados destes estudos.

Técnicas e desenho experimental

- Estatística: regressão linear múltipla, ridge, regressão polinomial.
- Machine Learning: árvore de decisão, Random Forest, Gradient Boosting.
- Alvo transformado por $\log_{10}$ (assimetria); métricas na escala original (CAD/ano).
- Split temporal: treino 2020–2024, teste 2025 (evita vazamento entre períodos).
- Dois cenários: explicativo (inclui uso do ano) e preditivo (histórico defasado + atributos).
- Métricas: R^2 , RMSE e MAE.

Procedimento passo a passo

- 0 Mapeamento e extração** — identifica tabelas-chave, cria scripts SQL para exportar CSVs e desnormaliza as fontes em uma base consolidada.
- 1 Fonte única** — CSV consolidado fato_wo_ml (223.590 OS · 9.859 carretas únicas).
- 2 Qualidade e integridade** — consistência dos registros e exclusão de estornos (custos negativos).
- 3 Base carreta × ano** — define o alvo Y = custo anual de manutenção por carreta (47.666 linhas).
- 4 Deflação — CPI Canadá** — custos trazidos a CAD reais de dez/2025, comparáveis no tempo.
- 5 EDA** — descritivas, distribuições e relação de cada variável com o custo.
- 6 Seleção anti-vazamento** — remove componentes do próprio Y e usa histórico só do ano anterior.
- 7 Modelagem — split temporal** — treino 2020–2024 / teste 2025; lineares, árvores e ensembles.
- 8 Avaliação e conclusões** — R^2 / RMSE / MAE, importância das variáveis e recomendações.
- 9 Aplicação ao planejamento** — apoia o controle dos custos internos e a elaboração de orçamentos mais aderentes à idade, às especificações e à aplicação de cada equipamento da frota.
- 10 Deployment e atualização contínua** — disponibiliza os scripts de ML para integração com APIs que alimentem o pipeline trimestralmente, permitindo revalidar e atualizar os resultados do modelo.

Limitações metodológicas

- Fonte inicial: sem dados de contrato, mão de obra detalhada e peças — reduz o conjunto explicativo.
- Sem filtro por tipo de manutenção: analisa-se todo o custo interno.
- km derivado do odômetro nas OS; resets/ruído tratados por regra, com aproximação.
- Província parcial (~54%); região usada como proxy geográfica.
- Estornos (custos negativos) excluídos; span ativo assume presença entre 1ª e última OS.

Entregas do Projeto

Gate 1 - Dados e qualidade

Concluída

- Inventário das bases: carretas, OS, mão de obra, peças, contratos, odômetro e GPS.
- Validação de chaves, datas, custos negativos/zerados, leituras de odômetro e ausentes.
- Documentação das regras de tratamento e dos riscos metodológicos.

Gate 3 - EDA e hipóteses

Concluída

- Distribuições, outliers, assimetria, correlações, VIF e segmentações.
- Custos e OS têm distribuição assimétrica, com poucos casos extremos.
- Índícios de efeito de idade, histórico, sistemas VMRS e perfil operacional.

Gate 5 - Validação e robustez

Próximos passos

- Verificar estabilidade por ano de teste, região, tipo de carreta e perfil de manutenção.
- Testar sensibilidade a outliers, seleção de variáveis e hiperparâmetros.
- Avaliar extensões: MERF, modelos hierárquicos e abordagens zero-infladas.

Gate 2 - Base analítica

Concluída

- Construção da base carreta x ano para custo anual real de manutenção.
- Criação de variáveis defasadas para evitar vazamento temporal.

Gate 4 - Modelo anual de custo

Próximos passos

- Modelo em grão carreta x ano, com custo anual real deflacionado.
- Resultados promissores, superiores aos modelos lineares no teste temporal.
- Fatores: nº de OS, VMRS, custo acumulado, subtipo, km e região.

Gate 6 - Interpretação de negócio

Próximos passos

- Traduzir resultados em recomendações para orçamento, preventiva e gestão da frota.
- Separar fatores de risco operacional das limitações de dados e ruído de medição.
- Reforçar que os achados são preditivos e exploratórios, sem inferência causal.